Introduction

L'entreprise HumanForYou subit depuis quelques années un turn-over d'environ 15% de ses employés tous les ans et nécessite de retrouver des profils similaires sur le marché de l'emploi. Celle-ci cherche à savoir les raisons de tous ces départs et a fait appel à notre équipe de spécialistes afin d'identifier ces différentes raisons. Ce document va donc présenter le compte rendu de l'analyse des données commandité par la direction de l'entreprise.

Problématiques générales

- Quels sont les facteurs ayant le plus d'influence sur ce taux de turn-over ?
- Comment réduire ce taux de turn-over ?

Objectifs

Les deux principaux objectifs de ce document sont de mettre en avant les différentes raisons possibles qui poussent les employés à changer d'entreprise tous les ans et de proposer des solutions à ce problème.

Périmètre des données utilisées

Données fondamentales :

- Nombre d'employés : 4410
- Jeux de données au format CSV :
  - Données générales sur les employés : *general_data*
  - Données du sondage de satisfaction des employés dans l'entreprise : *employee_survey_data*
  - Données sur les évaluations du manager : *manager_survey_data*
  - Données sur les horaires d'entrée au bureau : *in_time*
  - Données sur les horaires de sortie du bureau : *out_time*

Plan d'action

Afin de répondre aux problématiques, le plan d'action suivant s'est dessiné :

- Étape n°1 - Préparation des données
- Étape n°2 - Explication des indicateurs
- Étape n°3 - Entrainement des modèles
- Étape n°4 - Interprétation des résultats

Étape n°1 - Préparation des données

Fonction de sauvegarde des graphiques

Dans le futur, lors de l'affichage des graphiques, ces derniers, par soucis de visibilité, serons enregistrés en local sur l'ordinateur grâce la fonction suivante *save_fig()* :

In [1]:
```
import matplotlib
import matplotlib.pyplot as plt
import seaborn as sns

def save_fig(fig_id):
    plt.tight_layout()
    plt.savefig(os.path.join(fig_id + ".png"), format="png", dpi=300)
```

Fonction d'importation des données

Actuellement, le jeu de données total est composé de cinq fichiers au format CSV. Ces fichiers sont à importer et à transformer en DataFrame pandas (bibliothèque Python prévue pour l'analyse et le traitement de données). Pour éviter de dupliquer le code qui importe ces jeux de données, une fonction *load_data()* a été créée afin d'importer un fichier et de le transformer en DataFrame automatiquement.

In [2]:
```
import os
import pandas as pd

def load_data(file):
    return pd.read_csv(file)
```

Importation des données

Comme son nom l'indique, cette partie importe les jeux de données dans des DataFrames sans aucune modification.

In [3]:
```
path = "./datasets/"
general_data = load_data(path +"general_data.csv")
employee_survey_data = load_data(path +"employee_survey_data.csv")
manager_survey_data = load_data(path +"manager_survey_data.csv")
in_time = load_data(path +"in_time.csv")
out_time = load_data(path +"out_time.csv")
```

Jointure des données

Pour la suite du travail, les actions seront effectuées sur une copie du dataset *general_data* afin d'éviter tout soucis.

In [4]:
```
general_data_copy = general_data.copy()
```

Maintenant qu'une copie de *general_data* est créée, les deux datasets *employee_survey_data* et *manager_survey_data* sont joints via la colonne "EmployeeID".

Pour rappel :

- *employee_survey_data* contient les réponses au questionnaire du service RH sur la qualité de vie au travail
- *manager_survey_data* contient les évaluations faites par les managers pour chaque employé

In [5]:
```
general_data_copy = general_data_copy.join(employee_survey_data.set_index("EmployeeID"), on="EmployeeID")
```

In [6]:
```
general_data_copy = general_data_copy.join(manager_survey_data.set_index("EmployeeID"), on="EmployeeID")
```

Temps

Les deux jeux de données *in_time* et *out_time*, énumèrent les badges d'entrée et de sortie de chaque employé durant la période du 1er janvier au 31 décembre 2015. Les dates de ces jeux de données seront converties en datetime puis en timestamp pour les manipuler plus simplement à postériori.

In [7]:
```
import numpy as np

in_time= in_time.dropna(axis=1, how='all').fillna(0)
out_time = out_time.dropna(axis=1, how='all').fillna(0)

for col in in_time.keys()[1:]:
    in_time[col] = pd.to_datetime(in_time[col]).values.astype(np.int64) // 10 ** 9

for col in out_time.keys()[1:]:
    out_time[col] = pd.to_datetime(out_time[col]).values.astype(np.int64) // 10 ** 9
```

Une fois cela fait, un tri est effectué afin de les avoir dans l'ordre croissant par rapport à l'identifiant des employés.

In [8]:
```
in_time = in_time.sort_values(by="Unnamed: 0", ascending=True)
out_time = out_time.sort_values(by="Unnamed: 0", ascending=True)
```

Par la suite, un calcul sur la différence entre les horaires d'entrée et les horaires à la sortie des employés pour chaque jour sera effectué afin d'obtenir le temps de travail journalier.

Avant de faire cela, la colonne des identifiants sera ajoutée à elle-même. Cela aura pour effet, durant la soustraction des colonnes, de garder l'identifiant de l'employé intact.

In [9]:
```
out_time["Unnamed: 0"] = out_time["Unnamed: 0"] + out_time["Unnamed: 0"]
time = out_time.subtract(in_time, axis=1)
```

Une fois le calcul du temps journalier terminé, nous effectuons à nouveau une soustraction, cette fois-ci, entre le temps journalier effectué par l'employé et le temps de travail journalier inscrit dans son contrat.

Par la suite, les valeurs inférieures (les temps de retard) sont remplacées par -1 et les valeurs supérieures (les temps d'heures supplémentaires) sont remplacées par 1.

Enfin, ces valeurs sont additionnées pour obtenir un score d'assiduité pour chaque employé à l'année, ces valeurs seront stockées dans une colonne appelée *AttendanceScore*.

In [10]:
```
time_tmp = time.copy()
time_tmp = time_tmp.join(general_data.set_index("EmployeeID"), on="Unnamed: 0")
time_tmp["EmployeeID"] = time_tmp["Unnamed: 0"]
time_tmp["StandardHours"] = time_tmp["StandardHours"] * 3600
time_tmp["AttendanceScore"] = 0

for date in time_tmp.keys()[1:len(time.keys()[1:]) +1]:
    time_tmp[date] = time_tmp[date] - time_tmp["StandardHours"]
    time_tmp[date] = time_tmp[date].where(time_tmp[date] > 0, -1)
    time_tmp[date] = time_tmp[date].where(time_tmp[date] < 0, 1)
    time_tmp["AttendanceScore"] = time_tmp["AttendanceScore"] + time_tmp[date]
```

Puis, la colonne *AttendanceScore* est fusionnée au dataset général via la colonne *EmployeeID*.

In [11]:
```
general_data_copy = pd.merge(general_data_copy,time_tmp[['EmployeeID', 'AttendanceScore']],on='EmployeeID', how
```

Suppression des colonnes

Éthique

Pour s'assurer de l'éthique des données, il a été décidé de supprimer les colonnes non conformes à l'éthique selon notre jugement. Il a donc été décidé en comparant les recommandations de la Commission Européenne (voir le livrable éthique) de supprimer quatre colonnes : *Age*, *Over18*, *Gender*, *MaritalStatus*.

In [12]:
```
general_data_copy.drop("Age", axis=1, inplace=True) # Âge
general_data_copy.drop("Over18", axis=1, inplace=True) # Âge
general_data_copy.drop("Gender", axis=1, inplace=True) # Sexe
general_data_copy.drop("MaritalStatus", axis=1, inplace=True) # Statut marital
```

Autre

Par la suite, deux autres colonnes ont été supprimées. La première colonne est *EmployeeCount* car il n'existe qu'une seule valeur pour l'ensemble des employés. Ceci implique que la variance de cette colonne est très faible ce qui peut provoquer des résultats faux et un algorithme n'étant pas robuste en cas de nouvelle valeur.

In [13]:
```
general_data_copy.EmployeeCount.value_counts()
```

Out[13]:
```
1    4410
Name: EmployeeCount, dtype: int64
```

La seconde colonne est *StandardHours* (nombre journalier d'heures prévues dans le contrat pour chaque employé), parce qu'elle est elle-même liée à la colonne *AttendanceScore* que nous avons déjà calculée plus tôt.

In [14]:
```
general_data_copy.drop("EmployeeCount", axis=1, inplace=True)
general_data_copy.drop("StandardHours", axis=1, inplace=True)
```

Numérisation des types catégoriels

La numérisation des données va permettre d'utiliser et de manipuler beaucoup plus facilement des données catégorielles. Ces mêmes catégories seront remplacées par des nombres chacun faisant référence à une catégorie bien spécifique. Tout d'abord, les valeurs de la colonne *Attrition* qui sont soit 'Yes', soit 'No', sont respectivement remplacées par les valeurs 1 et -1.

In [15]:
```
general_data_copy["Attrition"] = general_data_copy["Attrition"].replace(to_replace=['No', 'Yes'], value=[-1, 1]
```

Pour réaliser cela, il est courant d'utiliser des encodeurs tels que l'OrdinalEncoder. Celui-ci permet notamment de transformer nos catégories en nombres numérotés automatiquement.

Exemple : "gauche", "droite" et "devant" en 0, 1 et 2 respectivement.

In [16]:
```
from sklearn.preprocessing import OrdinalEncoder
ordinal_encoder = OrdinalEncoder()

general_data_copy.EducationField = ordinal_encoder.fit_transform(general_data_copy[["EducationField"]])
general_data_copy.BusinessTravel = ordinal_encoder.fit_transform(general_data_copy[["BusinessTravel"]])
general_data_copy.Department = ordinal_encoder.fit_transform(general_data_copy[["Department"]])
general_data_copy.JobRole = ordinal_encoder.fit_transform(general_data_copy[["JobRole"]])
```

Transformation des taux (feature scaling)

La colonne *PercentSalaryHike* étant un pourcentage, celle-ci est réduite en divisant ses valeurs par 100, ce qui permet de créer une meilleure échelle de comparaison par rapport aux autres colonnes.

In [17]:
```
general_data_copy["PercentSalaryHike"] = general_data_copy["PercentSalaryHike"] / 100
```

Nettoyage des données

Puis les valeurs de type NaN (données vides) sont remplacée par 0.

In [18]:
```
general_data_copy = general_data_copy.fillna(0)
```

Corrélation

Maintenant que toutes les données sont mises en forme, des calculs de corrélations entre les colonnes sont implémentés. Le but étant de proposer un premier aperçu des raisons possibles de ce turn-over qui sera confirmé à la fin de ce présent document.

Méthode aidant à la visualisation de la corrélation

La fonction *retain_terminal* prend en paramètre un DataFrame et va appliquer un filtre afin de remplacer les valeurs comprises entre -0.1 et 0.1 par 0. Ceci va permettre de visualiser beaucoup plus facilement les colonnes les plus influentes (s'éloignant d'un score de corrélation de 0).

In [19]:
```
def retain_terminal(frame):
    for i in frame.keys():
        for a in range(len(frame[i])):
            if frame[i][a] > 0.1 or frame[i][a] < -0.1:
                frame[i][a] = frame[i][a]
            else:
                frame[i][a] = 0
    return frame
```

La fonction *separation_significant_parameters* vient en complément de la fonction précédente, celle-ci permet de séparer les paramètres considérés comme significatifs et qui n'auront donc pas été remplacés par 0 et les paramètres non significatifs qui auront été remplacés par 0.

In [20]:
```
def separation_significant_parameters(frame):
    significient_parameter = []
    insignificient_parameter = []
    for i in frame.keys():
        if frame[i].value_counts()[0] == len(frame[i]) - 1:
            insignificient_parameter.append(i)
        else:
            significient_parameter.append(i)
    return significient_parameter, insignificient_parameter
```

Calculs et visualisation des corrélations

Ensuite, l'ensemble des corrélations est calculé avec la méthode Pearson.

In [21]:
```
corr_data = general_data_copy.corr()
```

Le filtre précédemment défini est appliqué afin de supprimer le bruit (valeur entre -0.1 et 0.1) pour mieux visualiser les corrélations fortes.

In [22]:
```
corr_data = retain_terminal(corr_data)
```

Une fois que les corrélations ont été calculées, une visualisation est créée à l'aide d'une HeatMap. Une HeatMap permet d'afficher des résultats avec différentes couleurs en fonction de la valeur de ce résultat et permet également d'afficher une annotation pour vérifier le score de corrélation.

In [23]:
```
plt.figure(figsize=(20,18))
sns.heatmap(corr_data, annot = True, cmap=plt.get_cmap("jet"))
save_fig("./outputs/heatmap_correlation_pearson-jet")
```

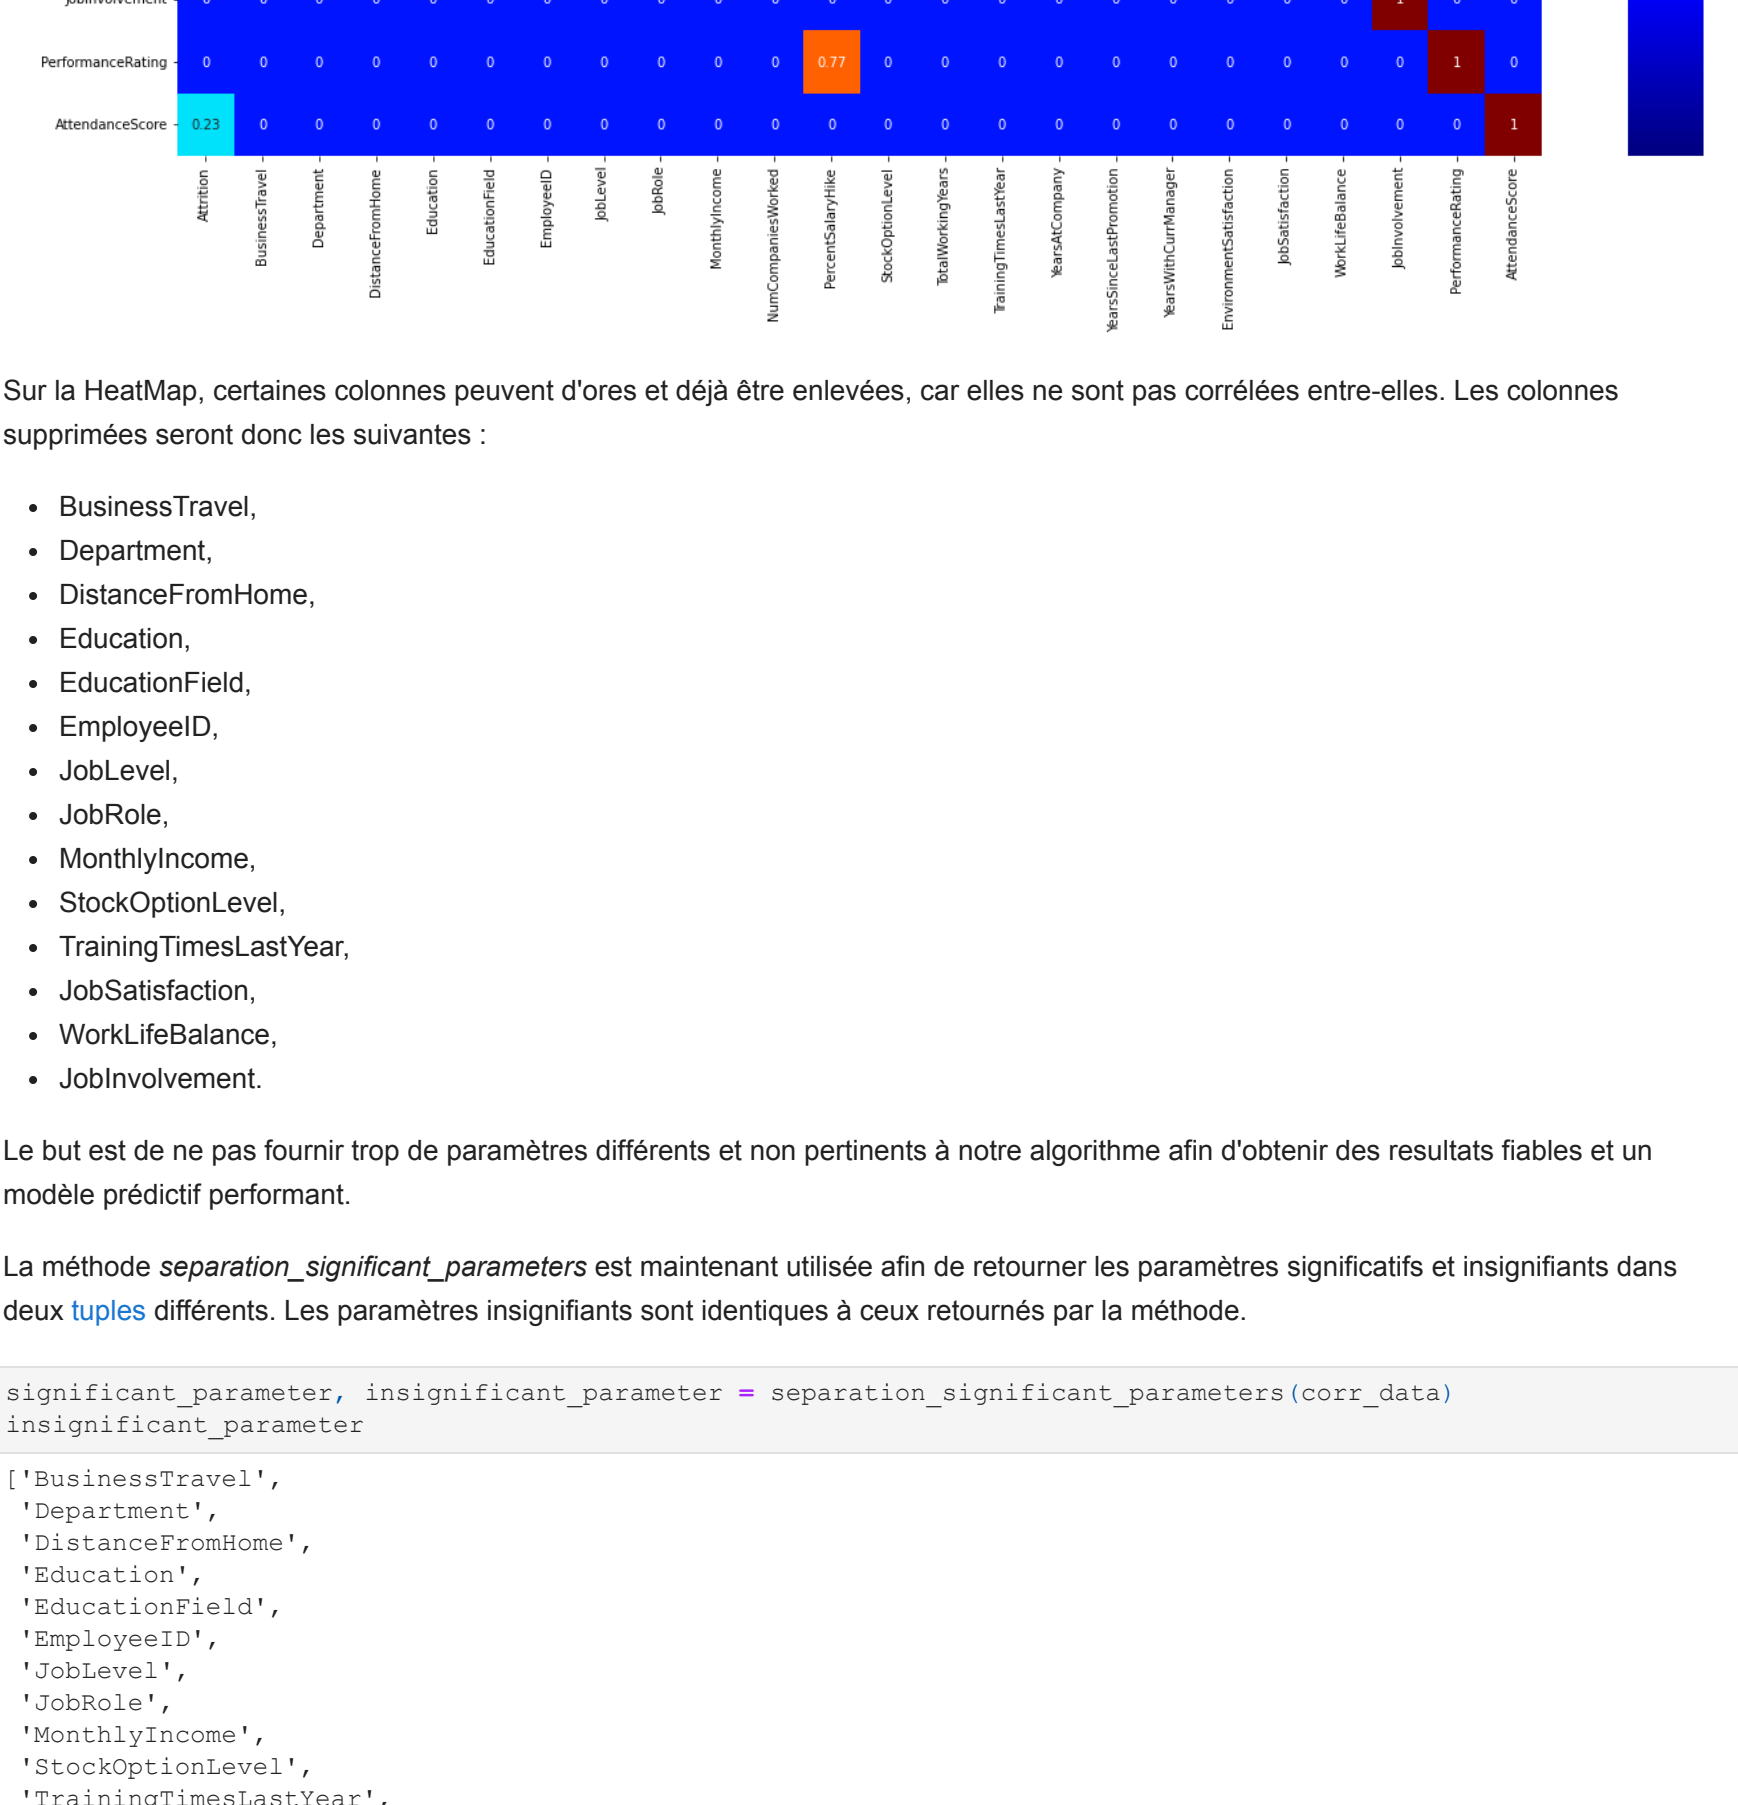

Sur la HeatMap, certaines colonnes peuvent d'ores et déjà être enlevées, car celles-ci ne sont pas corrélées entre-elles. Les colonnes supprimées seront donc les suivantes :

- BusinessTravel,
- Department,
- DistanceFromHome,
- Education,
- EducationField,
- EmployeeID,
- JobLevel,
- JobRole,
- MonthlyIncome,
- StockOptionLevel,
- TrainingTimesLastYear,
- JobSatisfaction,
- WorkLifeBalance,
- JobInvolvement.

Le but est de ne pas fournir trop de paramètres différents et non pertinents à notre algorithme afin d'obtenir des résultats fiables et un modèle prédictif performant.

La méthode *separation_significant_parameters* est maintenant utilisée afin de retourner les paramètres significatifs et insignifiants dans des tuples différents. Les paramètres insignifiants sont identiques à ceux retournés par la méthode.

In [24]:
```
significant_parameter, insignificant_parameter = separation_significant_parameters(corr_data)
insignificant_parameter
```

Out[24]:
```
['BusinessTravel',
 'Department',
 'DistanceFromHome',
 'Education',
 'EducationField',
 'EmployeeID',
 'JobLevel',
 'JobRole',
 'MonthlyIncome',
 'StockOptionLevel',
 'TrainingTimesLastYear',
 'JobSatisfaction',
 'WorkLifeBalance',
 'JobInvolvement']
```

Une nouvelle HeatMap avec uniquement les corrélations les plus fortes est générée avec le même traitement que le précédent.

In [25]:
```
corr_tmp = general_data_copy[significant_parameter].corr()
corr_tmp = retain_terminal(corr_tmp)

plt.figure(figsize=(20,18))
sns.heatmap(corr_tmp, annot = True, cmap=plt.get_cmap("jet"))#, mask=np.triu(np.ones_like(corr_tmp, dtype=bool)
save_fig("./outputs/heatmap_correlation_pearson-jet-without-columne")
```

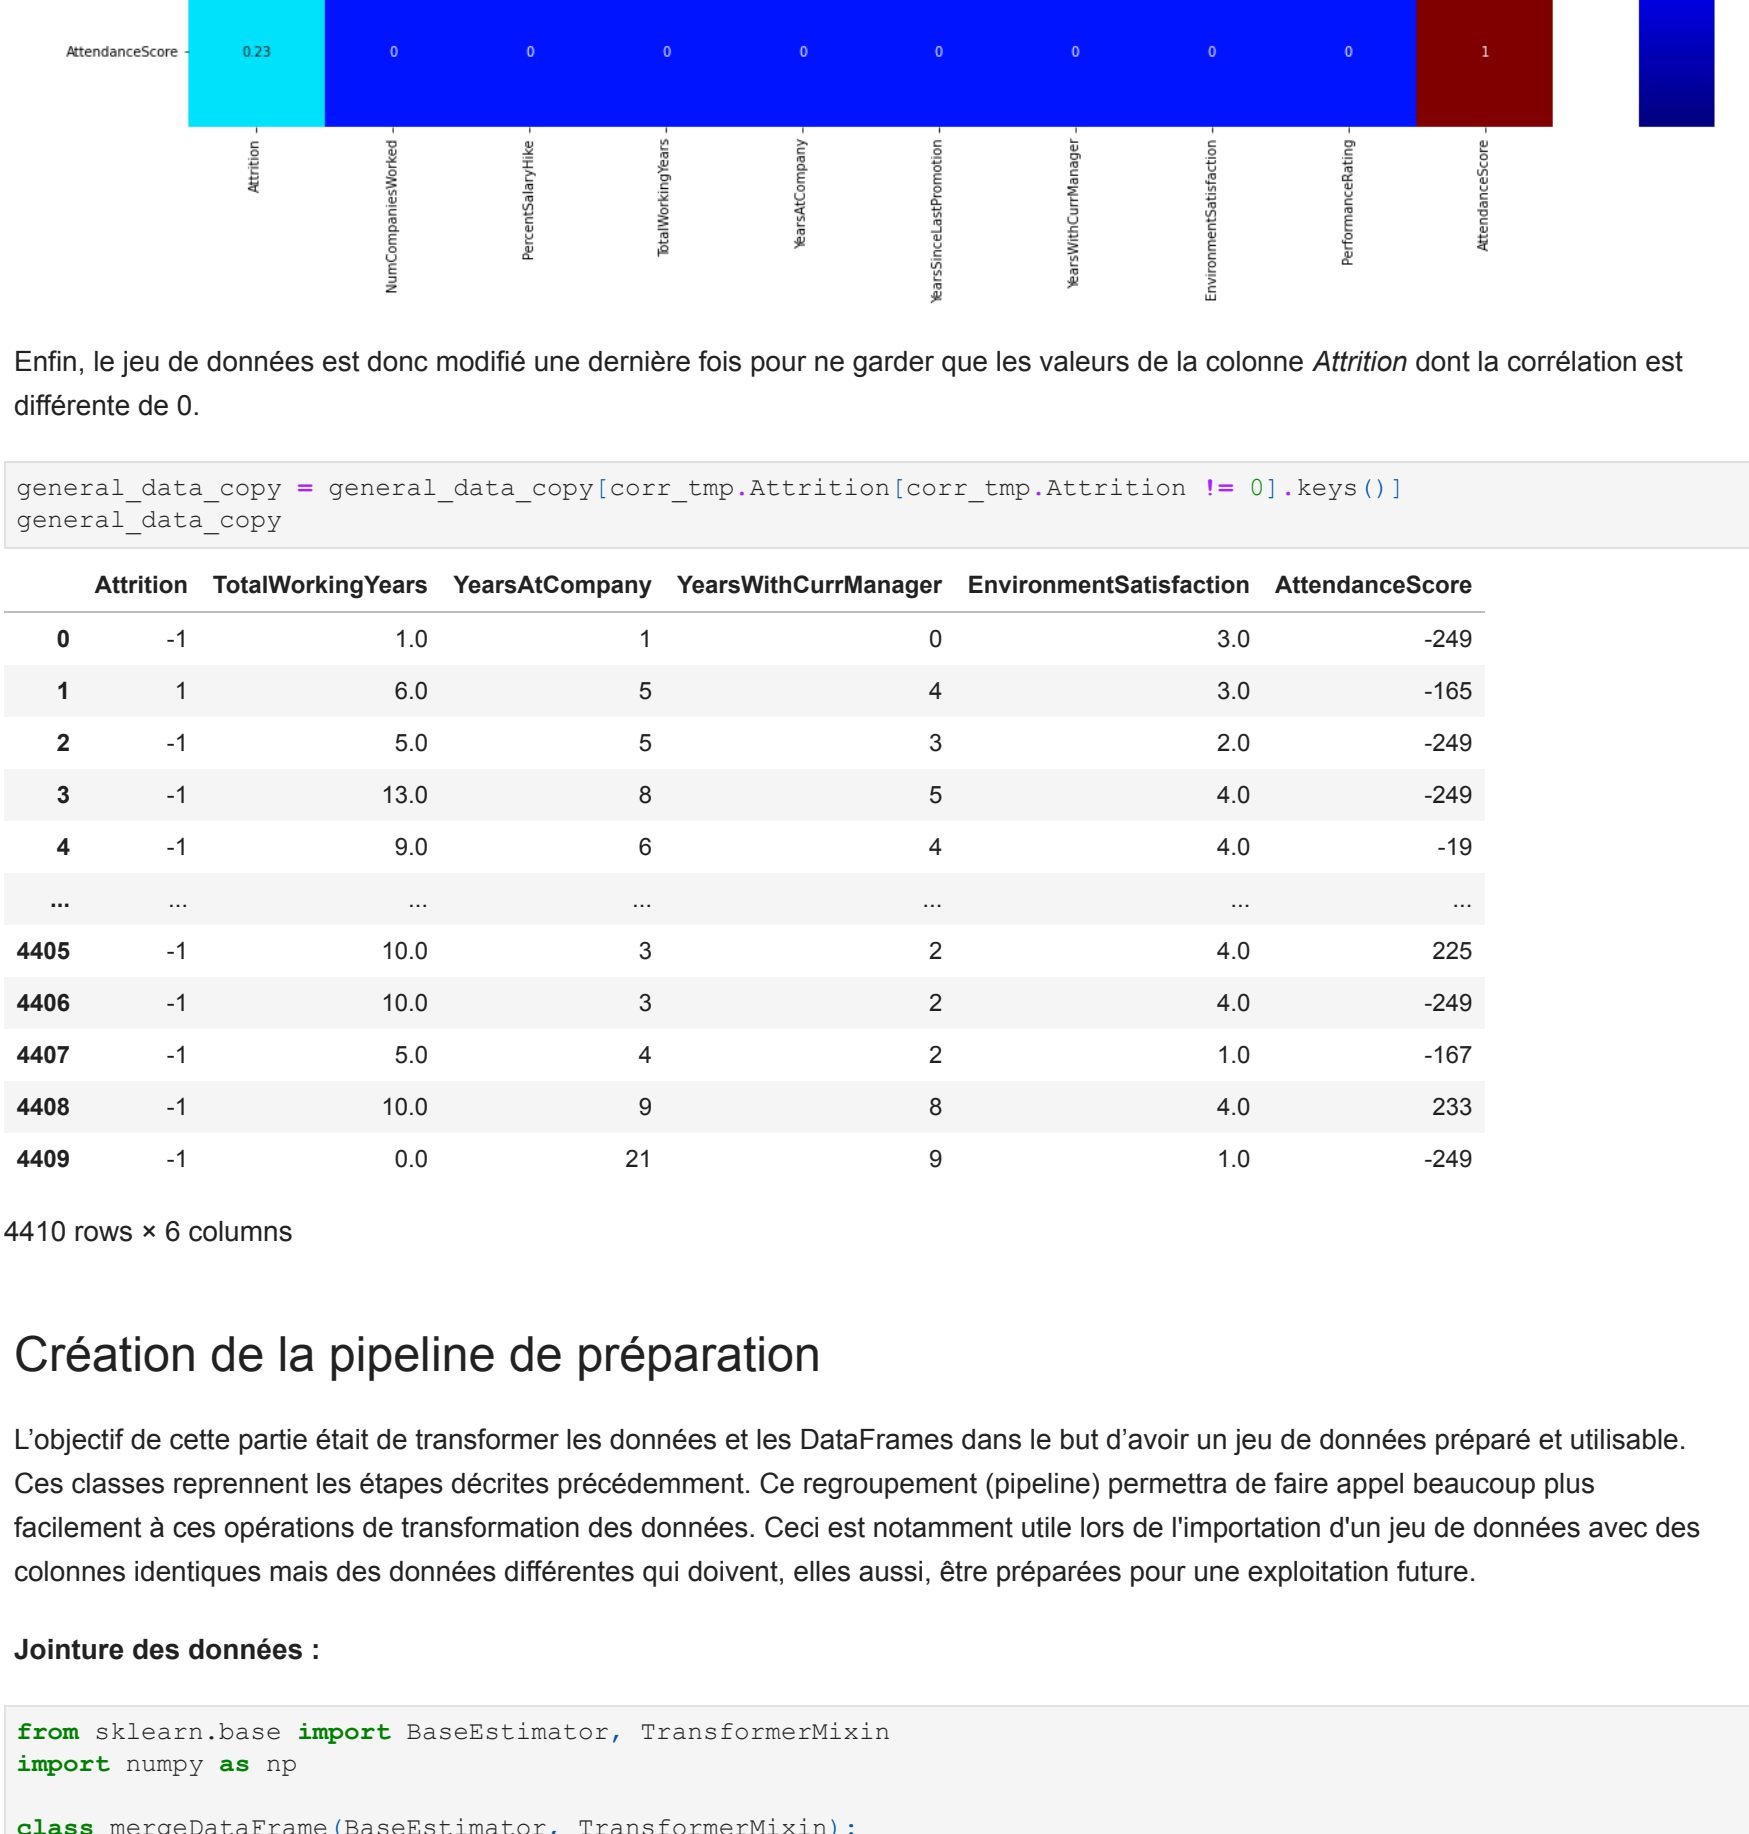

Enfin, le jeu de données est donc modifié une dernière fois pour ne garder que les valeurs de la colonne *Attrition* dont la corrélation est différente de 0.

In [26]:
```
general_data_copy = general_data_copy[corr_tmp.Attrition[corr_tmp.Attrition != 0].keys()]
general_data_copy
```

Out[26]:

	Attrition	TotalWorkingYears	YearsAtCompany	YearsWithCurrManager	EnvironmentSatisfaction	AttendanceScore
0	-1	1.0	1	0	3.0	-249
1	1	6.0	5	4	3.0	-165
2	-1	5.0	5	3	2.0	-249
3	-1	13.0	8	5	4.0	-249
4	-1	9.0	6	4	4.0	-19
...	...	...	...	...	...	...
4405	-1	10.0	3	2	4.0	225
4406	-1	10.0	3	2	4.0	-249
4407	-1	5.0	4	2	1.0	-167
4408	-1	10.0	9	8	4.0	233
4409	-1	0.0	21	9	1.0	-249

4410 rows × 6 columns

Création de la pipeline de préparation

L'objectif de cette partie était de transformer les données et les DataFrames dans le but d'avoir un jeu de données préparé et utilisable. Ces classes reprennent les étapes décrites précédemment. Ce regroupement (pipeline) permettra de faire appel beaucoup plus facilement à ces opérations de transformation des données. Ceci est notamment utile lors de l'importation d'un jeu de données avec des colonnes identiques mais des données différentes qui doivent, elles aussi, être préparées pour une exploitation future.

Jointure des données :

In [27]:
```
from sklearn.base import BaseEstimator, TransformerMixin
import numpy as np

class mergeDataFrame(BaseEstimator, TransformerMixin):
    def __init__(self, employee_survey_data, manager_survey_data, in_time, out_time):
        self.employee_survey_data = employee_survey_data
        self.manager_survey_data = manager_survey_data

        self.in_time= in_time.dropna(axis=1, how='all').fillna(0)
        self.out_time = out_time.dropna(axis=1, how='all').fillna(0)

        for col in self.in_time.keys()[1:]:
            self.in_time[col] = pd.to_datetime(self.in_time[col]).values.astype(np.int64) // 10 ** 9
        self.in_time = self.in_time.sort_values(by="Unnamed: 0", ascending=True)

        for col in self.out_time.keys()[1:]:
            self.out_time[col] = pd.to_datetime(self.out_time[col]).values.astype(np.int64) // 10 ** 9
        self.out_time["Unnamed: 0"] = self.out_time["Unnamed: 0"] + self.out_time["Unnamed: 0"]
        self.out_time = self.out_time.sort_values(by="Unnamed: 0", ascending=True)

    def fit(self, X, y=None):
        return self

    def transform(self, X, y=None):
        X = X.join(self.employee_survey_data.set_index("EmployeeID"), on="EmployeeID")
        X = X.join(self.manager_survey_data.set_index("EmployeeID"), on="EmployeeID")

        time = self.out_time.subtract(self.in_time, axis=1)

        time_tmp = time.copy()
        time_tmp = time_tmp.join(X.set_index("EmployeeID"), on="Unnamed: 0")
        time_tmp = time_tmp.rename(columns={"Unnamed: 0": "EmployeeID"})
        time_tmp["StandardHours"] = time_tmp["StandardHours"] * 3600
        time_tmp["AttendanceScore"] = 0

        for date in time_tmp.keys()[1:len(time.keys()[1:]) +1]:
            time_tmp[date] = time_tmp[date] - time_tmp["StandardHours"]
            time_tmp[date] = time_tmp[date].where(time_tmp[date] > 0, -1)
            time_tmp[date] = time_tmp[date].where(time_tmp[date] < 0, 1)
            time_tmp["AttendanceScore"] = time_tmp["AttendanceScore"] + time_tmp[date]

        X = pd.merge(X, time_tmp[['EmployeeID', 'AttendanceScore']], on='EmployeeID', how='left')

        return X
```

Suppression des colonnes n'étant pas éthiques :

In [28]:
```
class deleteEthicColumn(BaseEstimator, TransformerMixin):
    def __init__(self, array):
        self.array = array

    def fit(self, X, y=None):
        return self

    def transform(self, X, y=None):
        for i in self.array:
            X.drop(i, axis=1, inplace=True)
        return X
```

Convertion des données catégorielles en numériques :

In [29]:
```
from sklearn.preprocessing import OrdinalEncoder

class convertDataFrame(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        return self

    def transform(self, X, y=None):
        X["Attrition"] = X["Attrition"].replace(to_replace=['No', 'Yes'], value=[-1, 1])
        ordinal_encoder = OrdinalEncoder()
        for i in X.select_dtypes(include=["object"]).keys():
            X[i] = ordinal_encoder.fit_transform(X[[i]])
        return X
```

Nettoyage des données :

In [30]:
```
class cleaningDataFrame(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        return self

    def transform(self, X, y=None):
        X.PercentSalaryHike = X.PercentSalaryHike / 100
        X = X.fillna(0)
        return X
```

Corrélations des données :

In [31]:
```
class corrDataFrame(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        return self

    def transform(self, X, y=None):
        corr_x = self.retain_terminal(X.corr())
        significant_parameter, insignificant_parameter = self.separation_significant_parameters(corr_x)

        corr_tmp = X[significant_parameter].corr()
        corr_tmp = self.retain_terminal(corr_tmp)

        return X[corr_tmp.Attrition[corr_tmp.Attrition != 0].keys()]

    def retain_terminal(self, frame):
        for i in frame.keys():
            for a in range(len(frame[i])):
                if frame[i][a] > 0.1 or frame[i][a] < -0.1:
                    frame[i][a] = frame[i][a]
                else:
                    frame[i][a] = 0
        return frame

    def separation_significant_parameters(self, frame):
        significant_parameter = []
        insignificient_parameter = []
        for i in frame.keys():
            if frame[i].value_counts()[0] == len(frame[i]) - 1:
                insignificient_parameter.append(i)
            else:
                significant_parameter.append(i)
        return significant_parameter, insignificient_parameter
```

Le code suivant décrit toutes les étapes que le pipeline exécutera pour obtenir le jeu de données complet et final.

In [32]:
```
from sklearn.pipeline import Pipeline

pipeline = Pipeline([
    ("merge", mergeDataFrame(load_data(path +"employee_survey_data.csv"),
                             load_data(path +"manager_survey_data.csv"),
                             load_data(path +"in_time.csv"),
                             load_data(path +"out_time.csv"))),
    ("delete", deleteEthicColumn([
        "Age",
        "Over18",
        "Gender",
        "MaritalStatus",
        "EmployeeCount",
        "StandardHours"
    ])),
    ("convert", convertDataFrame()),
    ("clean", cleaningDataFrame()),
    ("corr", corrDataFrame())
])
```

Le pipeline est exécuté, puis le résultat est séparé en deux variables, la première *X* sont les paramètres donnés en entrée des modèles et le deuxième *y* le résultat attendu en sortie du modèle. Ces valeurs sont ensuite affichées.

In [33]:
```
dataset = pipeline.fit_transform(
    load_data(path +"general_data.csv")
)

labels = dataset.keys().to_list()
labels.remove('Attrition')

X = dataset[labels]
y = dataset['Attrition']

# Features
X
```

Out[33]:

	TotalWorkingYears	YearsAtCompany	YearsWithCurrManager	EnvironmentSatisfaction	AttendanceScore
0	1.0	1	0	3.0	-249
1	6.0	5	4	3.0	-165
2	5.0	5	3	2.0	-249
3	13.0	8	5	4.0	-249
4	9.0	6	4	4.0	-19
...	...	...	...	...	...
4405	10.0	3	2	4.0	225
4406	10.0	3	2	4.0	-249
4407	5.0	4	2	1.0	-167
4408	10.0	9	8	4.0	233
4409	0.0	21	9	1.0	-249

4410 rows × 5 columns

In [34]:
```
# Target
y
```

Out[34]:
```
0      -1
1       1
2      -1
3      -1
4      -1
       ..
4405   -1
4406   -1
4407   -1
4408   -1
4409   -1
Name: Attrition, Length: 4410, dtype: int64
```

Étape n°2 - Explication des indicateurs

Les indicateurs que nous utiliserons afin de vérifier les performances de notre modèle final sont présentés dans cette partie. Ces notions sont cruciales à comprendre et constituent ici une introduction à l'exploitation et l'interprétation finale de l'étude. Il est à noter que les fonctions utilisent à la fois la bibliothèque scikit-learn (sklearn) mais également des fonctions réalisées sans l'utilisation de bibliothèque spécifique afin de vérifier nos résultats et la bonne compréhension des métriques. Les indicateurs ci-dessous seront représentés avec des valeurs servant d'exemples et de démonstrations.

Définition

En Machine Learning, la bonne manière de procéder consiste à se baser sur des indicateurs mathématiques précis et concrets ouvrant la porte aux interprétations humaines. Généralement dans ce type de problèmes de classification, des indicateurs tels que des métriques de performance ou encore des courbes de comparaisons sont très utilisés.

Chaque indicateur de cette partie sera donc accompagnée d'une rapide description ainsi qu'une explication sur son utilisation et sur le résultat obtenu dans notre contexte.

Données de test

Afin de se concentrer uniquement sur la bonne compréhension des indicateurs, des résultats fictifs de modèles ont été crées et seront utilisés dans les prochains calculs :

In [35]:
```
virtual_resultat = [1, 1, 1, 1, -1, -1, -1, -1, -1, 1]
virtual_prediction = [1, 1, 1, 1, 1, 1, 1, -1, -1, -1]
```

Matrice de confusion

La matrice est de confusion est aujourd'hui l'un des outils les plus utilisés pour évaluer les performances d'un modèle de classification. Celle-ci présente un système de classes chacune associées à une valeur de représentation de cette classe suite à l'entrainement avec un modèle de prédictions. Il est à noter que ce type de matrice fonctionne aussi bien pour des problèmes de classification à 2 classes (binaires) ou plus.

Veuillez trouver ci-dessous un exemple de matrice de prédiction binaire :

		Predicted	
		1	0
Actual	1	TP	FN
	0	FP	TN

Comme présenté sur la figure, dans le cas binaire les classes sont :

- ***TP (True Positive)*** : les valeurs prédites positives par le modèle et qui se trouvent être positives au final (bonne prédiction)
- ***TN (True Negative)*** : les valeurs prédites négatives par le modèle et qui se trouvent être négatives au final (bonne prédiction)
- ***FP (False Positive)*** : les valeurs prédites positives par le modèle et qui se trouvent être négatives au final (mauvaise prédiction)
- ***FN (False Negative)*** : les valeurs prédites négatives par le modèle et qui se trouvent être positives au final (mauvaise prédiction)

Méthode "sklearn"

In [36]:
```
from sklearn.metrics import confusion_matrix

confusion_matrix(virtual_resultat, virtual_prediction)
```

Out[36]:
```
array([[2, 3],
       [1, 4]], dtype=int64)
```

Méthode "homemade"

In [37]:
```
import numpy as np
def homemade_confusion_matrix(y, predict):
    values_y = np.unique(y)[::-1]

    matrix = np.zeros((len(values_y), len(values_y)), dtype=int)
    for i in range(len(y)):
        matrix[np.where(values_y == y[i])[0][0]][np.where(values_y == predict[i])[0][0]] += 1

    return matrix
```

In [38]:
```
homemade_confusion_matrix(virtual_resultat, virtual_prediction)
```

Out[38]:
```
array([[4, 1],
       [3, 2]])
```

La matrice de confusion retournée par le code n'utilisant pas de bibliothèque n'affiche pas les valeurs dans l'ordre de celui avec bibliothèque. Il a été choisi de conserver l'ordre de la figure ci-dessus pour les *TP, TN, FP, FN* à des fins de compréhension. Quoi qu'il en soit, les valeurs sont évidemment les mêmes et sont correctes.

Métriques de performance

Une fois la matrice de confusion construite, les indicateurs peuvent maintenant se calculer. Ceux présentés dans cette partie sont ceux considérés comme les plus utiles pour l'étude et qui seront abordés dans la dernière partie.

Sensibilité, Recall, TPR : True Positive Rate

Cette métrique de performance représente le pourcentage d'employés quittant l'entreprise et étant bien détectés comme partant de l'entreprise par le modèle.

$$Recall = \frac{TP}{TP + FN}$$

Méthode "sklearn"

In [39]:
```
from sklearn.metrics import recall_score

recall = recall_score(virtual_resultat, virtual_prediction)
print(recall)
```

```
0.8
```

Méthode "homemade"

In [40]:
```
def homemade_recall_score(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return matrix[0][0] / (matrix[0][0] + matrix[0][1])
```

In [41]:
```
recall = homemade_recall_score(virtual_resultat, virtual_prediction)
print(recall)
```

```
0.8
```

Spécificité, TNR : True Negative Rate

Cette métrique de performance représente le pourcentage d'employés restant dans l'entreprise et donc les employés étant bien détectés comme restant dans l'entreprise.

$$TNR = \frac{TN}{TN + FP}$$

Méthode "homemade"

In [42]:
```
def homemade_specificity_score(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[1][1]) / (matrix[1][1] + matrix[1][0])
```

In [43]:
```
homemade_specificity_score(virtual_resultat, virtual_prediction)
```

Out[43]:
```
0.4
```

Fall out, FPR : False Positive Rate

Cette métrique de performance représente le pourcentage d'employés quittant l'entreprise, mais étant détectés comme restant dans l'entreprise.

$$FPR = \frac{FP}{TN + FP}$$

Méthode "homemade"

In [44]:
```
def homemade_fpr_calculator(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[1][0]) / (matrix[1][0] + matrix[1][1])
```

In [45]:
```
fpr = homemade_fpr_calculator(virtual_resultat, virtual_prediction)
print(fpr)
```

```
0.6
```

FNR : False negative Rate

Cette métrique de performance représente le pourcentage d'employés restant dans l'entreprise, mais étant détectés comme quittant l'entreprise.

$$FNR = \frac{FN}{FN + TP}$$

Méthode "homemade"

In [46]:
```
def homemade_fnr_calculator(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[0][1]) / (matrix[0][0] + matrix[0][1])
```

In [47]:
```
homemade_fnr_calculator(virtual_resultat, virtual_prediction)
```

Out[47]:
```
0.2
```

Précision, PPV : Positive Preditive Value

La valeur de prédiction positive représente le pourcentage de prédictions positives étant réellement correctes.

$$Precision = \frac{TP}{TP + FP}$$

Méthode "sklearn"

In [48]:
```
from sklearn.metrics import precision_score

precision = precision_score(virtual_resultat, virtual_prediction)
print(precision)
```

```
0.5714285714285714
```

Méthode "homemade"

In [49]:
```
def homemade_precision_score(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[0][0]) / (matrix[0][0] + matrix[1][0])
```

In [50]:
```
homemade_precision_score(virtual_resultat, virtual_prediction)
```

Out[50]:
```
0.5714285714285714
```

FDR : False Discovery Rate

Le taux de fausses découvertes représente le pourcentage de prédictions positives étant incorrectes.

$$FDR = 1 - PPV\frac{FP}{TP + FP}$$

Méthode "homemade"

In [51]:
```
def homemade_fdr_calculator(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[1][0]) / (matrix[0][0] + matrix[1][0])
```

In [52]:
```
homemade_fdr_calculator(virtual_resultat, virtual_prediction)
```

Out[52]:
```
0.42857142857142855
```

NPV : Negative Predictive Value

La valeur de prédiction négative représente le pourcentage de prédictions négatives étant réellement correctes.

$$NPV = \frac{TN}{TN + FN}$$

Méthode "homemade"

In [53]:
```
def homemade_npv_calculator(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[1][1]) / (matrix[1][1] + matrix[0][1])
```

In [54]:
```
homemade_npv_calculator(virtual_resultat, virtual_prediction)
```

Out[54]:
```
0.6666666666666666
```

FOR : False Omission Rate

Le taux de fausses omissions représente le pourcentage de prédictions négatives étant incorrectes.

$$FOR = 1 - NPV\frac{FN}{TN + FN}$$

Méthode "homemade"

In [55]:
```
def homemade_for_calculator(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[0][1]) / (matrix[1][1] + matrix[0][1])
```

In [56]:
```
homemade_for_calculator(virtual_resultat, virtual_prediction)
```

Out[56]:
```
0.3333333333333333
```

Accuracy, ACC

La justesse représente le pourcentage de prédictions correctes sur le total des prédictions.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Méthode "sklearn"

In [57]:
```
from sklearn.metrics import accuracy_score

accuracy_score(virtual_resultat, virtual_prediction)
```

Out[57]:
```
0.6
```

Méthode "homemade"

In [58]:
```
def homemade_accuracy_score(y, prediction):
    matrix = homemade_confusion_matrix(y, prediction)
    return (matrix[0][0] + matrix[1][1]) / (matrix[0][0] + matrix[0][1] + matrix[1][1] + matrix[1][0])
```

In [59]:
```
homemade_accuracy_score(virtual_resultat, virtual_prediction)
```

Out[59]:
```
0.6
```

F1-score

Le score F1 représente une évaluation de la performance de l'algorithme. Ce score est la moyenne harmonique de la précision et du rappel (cf: image ci-dessous).

Lorsque deux modèles ont une précision élevée et un faible *recall* ou inversement, la comparaison peut être plus compliquée. C'est pourquoi, dans ce type de situation, il est préférable d'utiliser le score F1 car il permet de mesurer ces deux paramètres simultanément.

$$F1 - Score = 2\frac{Precision * Recall}{(Precision + Recall)}$$

Méthode "sklearn"

In [60]:
```
from sklearn.metrics import f1_score

f1_score(virtual_resultat, virtual_prediction)
```

Out[60]:
```
0.6666666666666666
```

Méthode "homemade"

In [61]:
```
def homemade_f1_score(precision, recall):
    return 2 * (precision * recall) / (precision + recall)
```

In [62]:
```
homemade_f1_score(precision, recall)
```

Out[62]:
```
0.6666666666666666
```

Courbe ROC

La courbe ROC est un autre moyen d'évaluer un classificateur binaire. Elle confronte le taux de vrai positif (TPR ou recall) au taux de faux positif (FPR).

Méthode "sklearn"

In [63]:
```
from sklearn.metrics import roc_curve

false_pos, true_pos, thresholds = roc_curve(virtual_resultat, virtual_prediction)
```

In [64]:
```
import matplotlib.pyplot as plt

def plot_roc_curve(false_pos,true_pos, label=None):
    plt.plot(false_pos, true_pos, linewidth=2, label=label)
    plt.plot([0, 1], [0, 1], 'k--')
    plt.axis([0, 1, 0, 1])
    plt.xlabel('False Positive Rate', fontsize=16)
    plt.ylabel('True Positive Rate', fontsize=16)
```

In [65]:
```
plot_roc_curve(false_pos, true_pos)
```

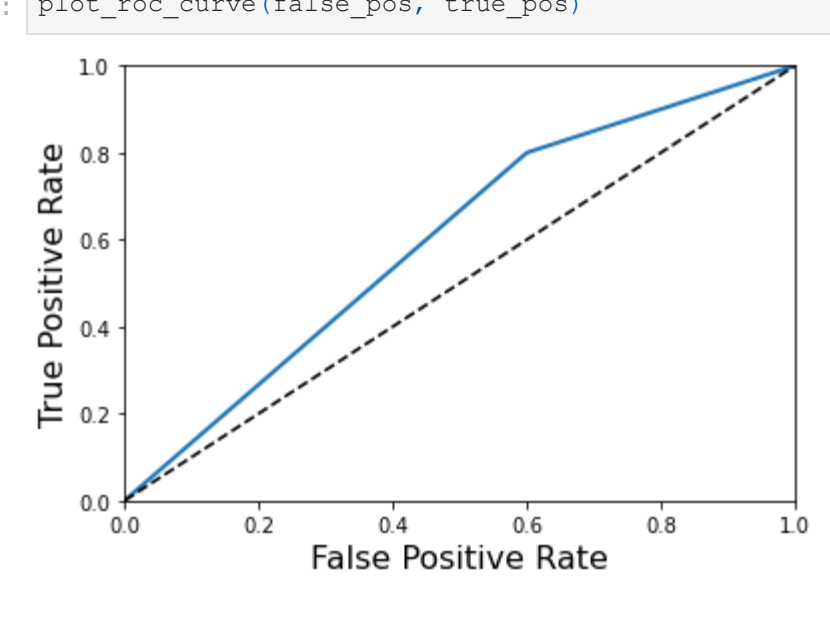

Méthode "homemade"

In [66]:
```
def homemade_roc_curve(y, predictions):
    thresholds = []

    false_pos = [0]
    true_pos = [0]

    for threshold in np.arange(-2, 2, 0.1):
        matrix = [0, 0, 0, 0]

        predicted = 0
        for j in range(0, len(predictions)):
            if(predictions[j] < threshold):
                predicted = -1
            else:
                predicted = 1

            if(predicted == -1 and y[j] == -1):
                matrix[0] += 1
            elif(predicted == -1 and y[j] == 1):
                matrix[1] += 1
            elif(predicted == 1 and y[j] == -1):
                matrix[2] += 1
            elif(predicted == 1 and y[j] == 1):
                matrix[3] += 1

        tp = matrix[3]
        fp = matrix[2]
        tn = matrix[0]
        fn = matrix[1]

        tpr = tp / (tp + fn) if tp + fn != 0 else 0
        fpr = fp / (fp + tn) if fp + tn != 0 else 0

        false_pos.append(fpr)
        true_pos.append(tpr)

        thresholds.append(threshold)

    return false_pos, true_pos, thresholds
```

In [67]:
```
false_pos, true_pos, thresholds = homemade_roc_curve(virtual_resultat, virtual_prediction)
plot_roc_curve(false_pos, true_pos)
```

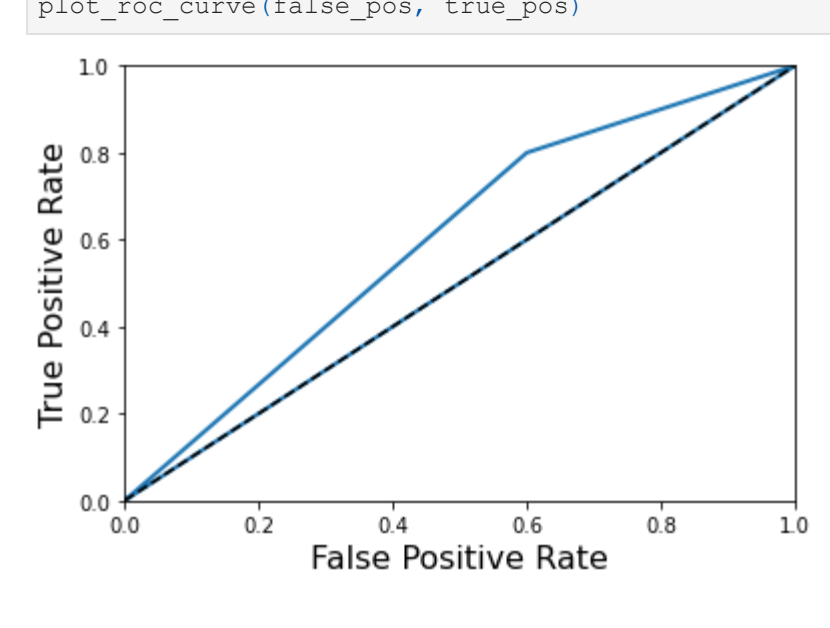

AUC

Pour la courbe ROC, un grand taux de vrais positifs implique beaucoup de faux positifs. La diagonale en pointillée représente la courbe ROC d'un classificateur aléatoire. Un classificateur idéal s'en écarte au maximum dans le coin supérieur gauche.

C'est pourquoi on utilise comme métrique de comparaison l'air sous la courbe ROC, nommé AUC, que l'on souhaite la plus proche possible de 1.

Méthode "sklearn"

In [68]:
```
from sklearn.metrics import roc_auc_score

roc_auc_score(virtual_resultat, virtual_prediction)
```

Out[68]:
```
0.6000000000000001
```

Méthode "homemade"

In [69]:
```
def homemade_auc_score(y, predictions):
    false_pos, true_pos, threshold = homemade_roc_curve(y, predictions)
    return np.trapz(false_pos, true_pos) + 0.5
```

In [70]:
```
homemade_auc_score(virtual_resultat, virtual_prediction)
```

Out[70]:
```
0.6000000000000001
```

Étape n°3 - Entrainement des modèles

Les données étant maintenant préparées et les métriques prêtes, la partie d'exploitation des modèles peut commencer. Elle abordera ici le choix des modèles ainsi que leur paramétrage pour obtenir un système fiable et performant.

Type de problème

L'objectif est de savoir si **oui** ou **non** l'employé a quitté l'entreprise en fonction de certains critères : c'est donc un problème de **classification binaire**. Les données étant fournies au préalable, le modèle de classification sera un **modèle supervisé**.

Résolution du problème

Voici une liste de différents modèles supervisés de classification que nous allons tester :

- Le Support Vector Classifier (SVC)
- L'Arbre de décision
- La Random Forest
- La Régression logistique binaire
- Le Nearest Neighbors
- Le Perceptron
- Le RidgeClassifier
- Le SGDClassifier

L'objectif principal étant de déterminer quels sont les **critères agissant le plus sur la décision des employés** de quitter l'entreprise. Il faut tout d'abord observer la capacité de ces différents modèles à classifier cette décision et ainsi **évaluer leur qualité**. Pour entrainer au mieux ces modèles nous allons utiliser la stratégie de la validation croisée (Cross Validation, CV). Cette stratégie va nous permettre de proposer au modèle, différentes séparations de notre jeu de données afin de trouver la séparation (entre données d'entrainement et données de test), la plus performante :

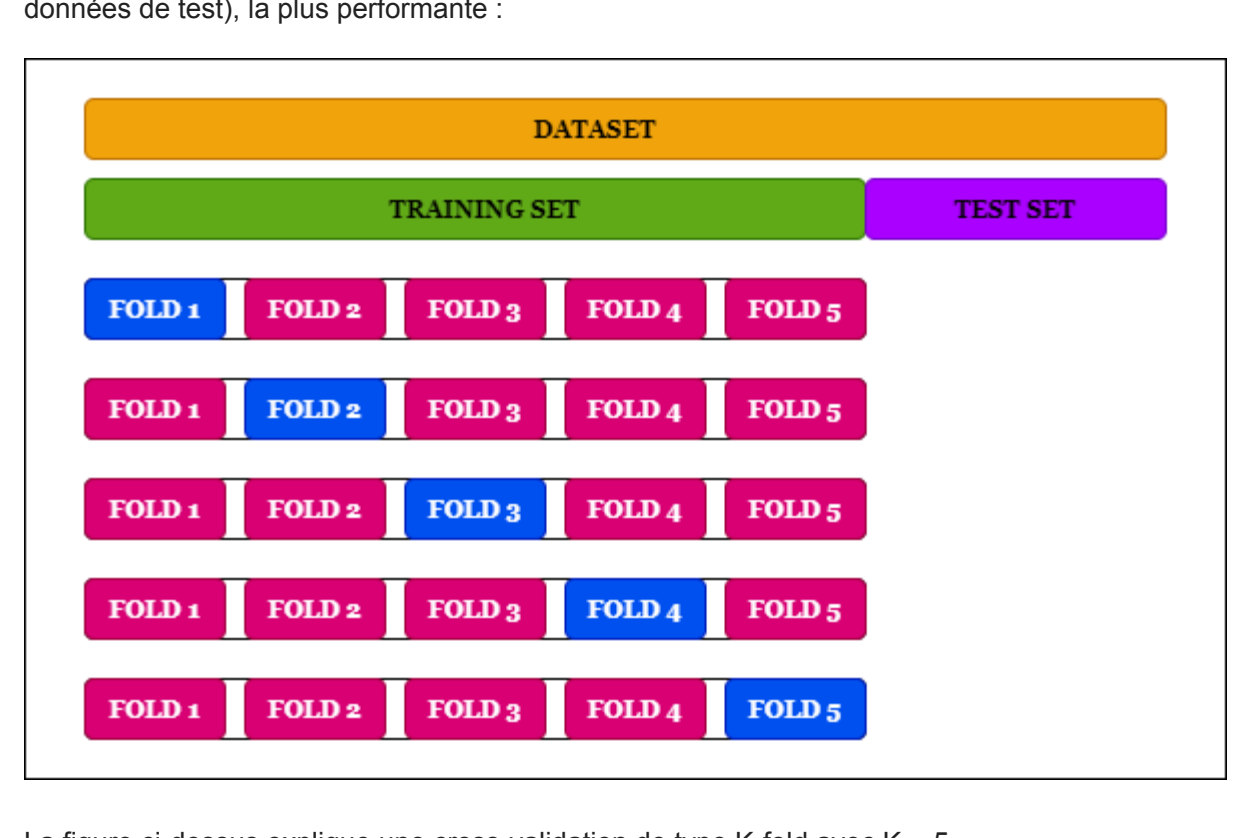

La figure ci-dessus explique une cross-validation de type K-fold avec K = 5.

Après avoir déterminé le meilleur modèle avec des **hyperparamètres idéaux** (paramètres relatifs au fonctionnement d'un modèle en particulier), les critères décisifs seront mis en avant. À l'aide de ces critères précis et du meilleur modèle trouvé, il sera possible de prévoir efficacement les décisions des employés.

Afin de tester l'efficacité de la librairie 'scikit-learn', des modèles vont être crées à la main.

Importations

In [71]:
```
import numpy as np
import pandas as pd
import os

from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import RidgeClassifier, SGDClassifier
from sklearn.metrics import roc_auc_score, roc_curve
from sklearn.model_selection import RandomizedSearchCV, GridSearchCV
from sklearn.model_selection import train_test_split

import warnings
warnings.filterwarnings('ignore')
```

Création de modèles

Régression logistique

Méthode avec l'utilisation de 'sklearn'

In [72]:
```
from sklearn.linear_model import LogisticRegression

regression_sklearn = LogisticRegression(random_state=42).fit(X, y)
predictions_regression_sklearn = regression_sklearn.predict(X)

score_regresssion_sklearn = regression_sklearn.score(X, y)
```

Méthode homemade

In [73]:
```
class HomemadeLogisticRegression:
    def __init__(self, iterations=1000, learning_rate=0.001):
        self.iterations = iterations
        self.learning_rate = learning_rate
        self.weights = 0
        self.bias = 0
        self.predictions = []

    def fit(self, X, y):
        n_target, n_feature = X.shape
        self.weights = np.zeros(n_feature)
        self.bias = 0

        for i in range(self.iterations):
            linear_model = np.dot(X, self.weights) + self.bias
            predictions = 1 / (1 + np.exp(-linear_model))

            gradientA = (1 / n_target) * np.dot(X.T, (predictions - y))
            gradientB = (1 / n_target) * np.sum(predictions - y)

            self.weights -= self.learning_rate * gradientA
            self.bias -= self.learning_rate * gradientB

        return self

    def predict(self, X):
        linear_model = np.dot(X, self.weights) + self.bias
        predictions = 1 / (1 + np.exp(-linear_model))
        predictions_classified = [1 if j > 0 else -1 for j in predictions]

        self.predictions = predictions_classified

        return np.array(predictions_classified)

    def score(self, X, y):
        return np.sum(y == self.predictions) / len(y)
```

In [74]:
```
regression_homemade = HomemadeLogisticRegression().fit(X, y)
predictions_homemade = regression_homemade.predict(X)

score_regresssion_homemade = regression_homemade.score(X, y)
```

Comparaison des deux méthodes

In [75]:
```
print("sklearn score :", score_regresssion_sklearn)
print("homemade score :", score_regresssion_homemade)
```

```
sklearn score : 0.8496598639455782
homemade score : 0.7145124716553288
```

Perceptron simple

Méthode avec l'utilisation de 'sklearn'

In [76]:
```
from sklearn.linear_model import Perceptron

perceptron_sklearn = Perceptron(random_state=42).fit(X, y)
predictions_sklearn = perceptron_sklearn.predict(X)

score_perceptron_sklearn = regression_sklearn.score(X,y)
```

Méthode homemade

In [77]:
```
class HomemadePerceptron:
    def __init__(self, iterations=1000, rate=0.001):
        self.iterations = iterations
        self.rate = rate

    def perceptron(self, X):
        return [1 if j == 1 else -1 for j in (X.dot(self.omega) + self.bias)]

    def fit(self, X, y):
        self.omega = np.random.rand(X.shape[1])
        self.bias = np.random.randn(1)

        for i in range(self.iterations):
            predicted = self.perceptron(X)

            dw = (1 / len(self.omega)) * np.dot(X.T, (predicted - y))
            db = (1 / len(self.omega)) * np.sum(predicted - y)

            self.omega -= self.rate * dw
            self.bias -= self.rate * db

        return self

    def predict(self, X):
        self.predictions = self.perceptron(X)

        return np.array(self.predictions)

    def score(self, X, y):
        return np.sum(y == self.predictions) / len(y)
```

In [78]:
```
perceptron_homemade = HomemadePerceptron().fit(X, y)
predictions_perceptron_homemade = perceptron_homemade.predict(X)

score_perceptron_homemade = perceptron_homemade.score(X, y)
```

Comparaison des deux méthodes

In [79]:
```
print("sklearn score :", score_perceptron_sklearn)
print("homemade score :", score_perceptron_homemade)
```

```
sklearn score : 0.8496598639455782
homemade score : 0.8387755102040816
```

Avec un score presque équivalent, il est possible de déduire que sklearn retourne des résultats fiables.

Résolution du problème avec des modèles paramètrables

Validation croisée (Cross Validation) : le paramètre k

Ce paramètre sera utilisé partout où la validation croisée sera nécessaire. Celui-ci indique le nombre k de partitions de taille égale qui seront découpées depuis les données initiales. Par convention, nous allons utiliser $k = 10$.

Cette valeur est très couramment utilisée et est conseillée par de nombreux spécialistes dans le domaine car elle donne généralement des résultats fiables.

Hyperparamètres

Hyperparamètres des modèles

L'objectif est de connaitre la valeur des hyperparamètres les plus pertinents en fonction des modèles appliqués à ce problème, certains d'entre eux sont utilisés presque partout, d'autres sont plus spécifiques à un modèle. Voici une définition de ceux que nous allons utiliser ainsi qu'une liste de valeur possible que nous appliquerons dans le code.

Chaque valeur a été choisie autour de la valeur par défaut fournie par les algorithmes, tout en respectant un certain pas d'une valeur à une autre d'un même hyperparamètre. Ces hyperparamètres seront testés et évalués par la suite grâce à la méthode `GridSearchCV`. Cette méthode va aussi nous fournir les meilleurs hyperparamètres en fonction du meilleur score trouvé (le classement du score se fera en fonction de l'accuracy, cependant, tous les indicateurs seront calculés). `GridSearchCV` va nous permettre de tester l'ensemble des cas possibles pour toutes les valeurs d'hyperparamètre sur un modèle donné (les intervalles de valeurs pour les hyperparamètres sont relativement petits comme décrit ci-dessous et offre donc cette possibilité sans grandement influer sur les performances) :

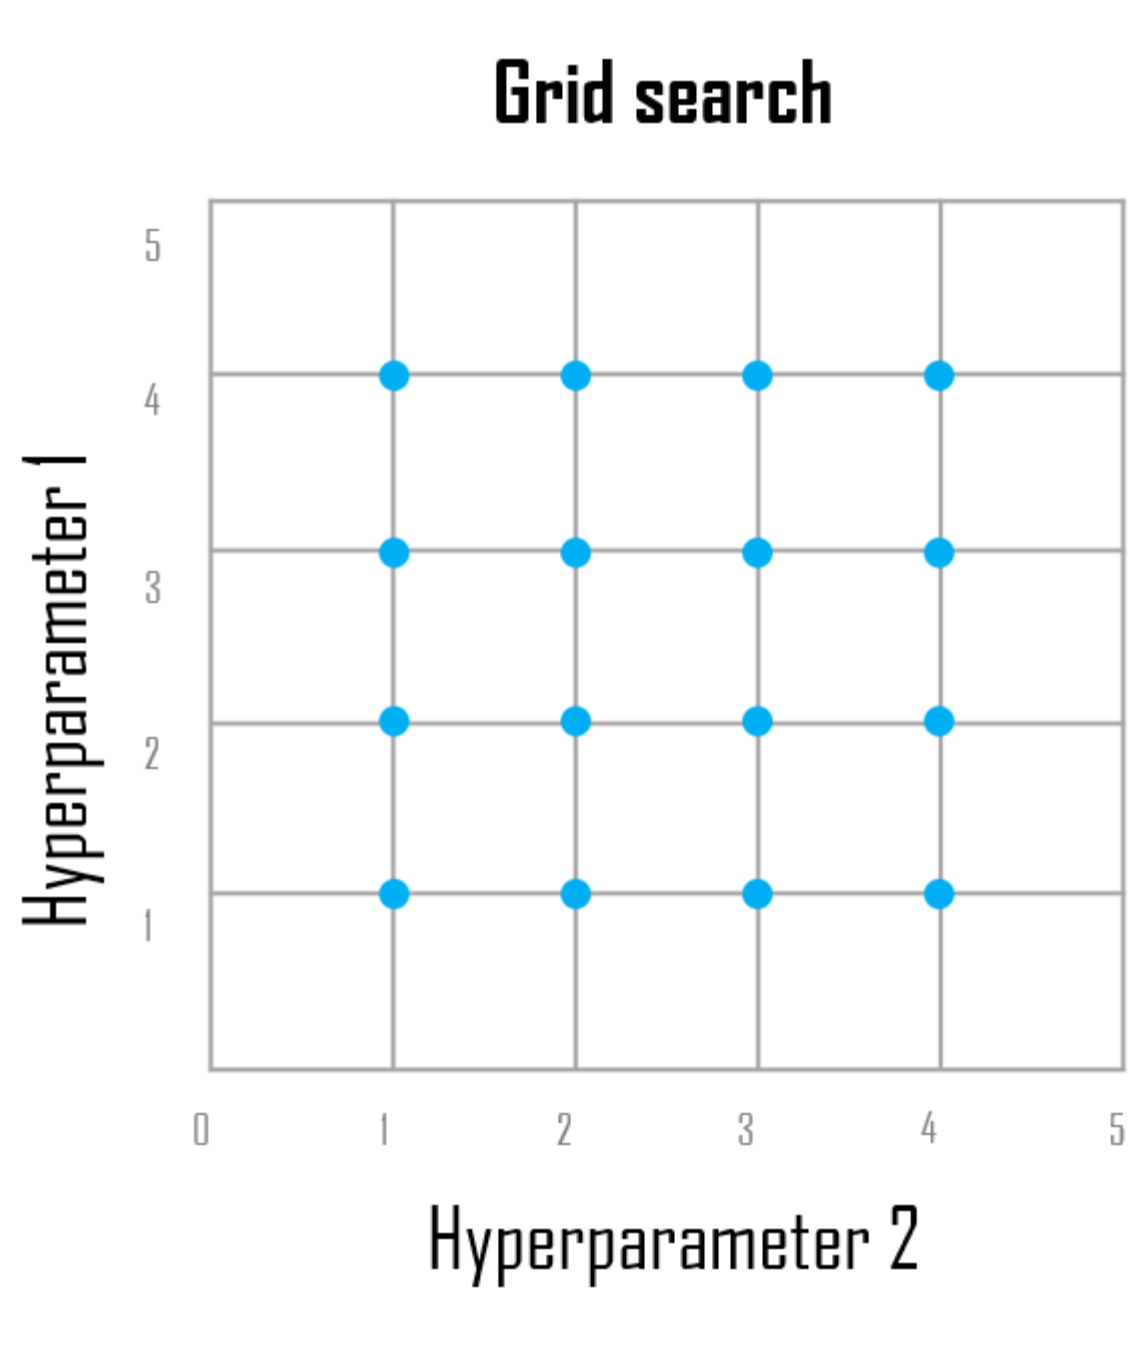

Les points bleus sur la figure représentent un entrainement du modèles avec les valeurs d'hyperparamètres correspondantes (tous les cas sont testés). Enfin, nous comparerons ces scores afin de déterminer le meilleur modèle.

Cas globaux

Rassemble les hyperparamètres utilisés sur l'ensemble des modèles sauf les modèles suivants : "Nearest Neighbors", "Arbre de décision" et "Random Forest"

- L'hyperparamètre `tol` définit la tolérance pour le critère d'arrêt. Il indique donc à l'algorithme d'arrêter la convergeance une fois qu'une certaine tolérance est atteinte. Plus la tolérance est petite, plus l'algorithme mettra du temps à converger. Il prendra les valeurs possible suivantes : $0.1, 0.01, 0.001, 0.0001, 0.00001$
- L'hyperparamètre `max_iter`, lui, définit le maximum d'itérations maximales dans la convergeance vers la tolérance donnée afin d'éviter les boucles infinies. Il prendra les valeurs possibles suivantes : $500, 1000, 1500, 2000$

Cas exceptionnel pour l'hyperparamètre `max_iter` :

La valeur par défaut de `max_iter` étant plus petite dans le modèle "Régression logistique binaire", le pas sera lui aussi plus petit. Voici donc les valeurs utilisées dans ce cas précis : $100, 200, 300, 400, 500, 600$

SVC

En plus des trois hyperparamètres cités précédemment, un de plus va être utilisé: il s'agit de l'hyperparamètre `kernel` celui-ci spécifie le type de noyau à utiliser dans l'algorithme. Il est au centre du fonctionnement du SVC et affecte grandement la séparabilité des classes ainsi que la performance de l'algorithme. Il prendra les valeurs suivantes : `'linear'`, `'poly'`, `'sigmoid'`, `'rbf'`.

DecisionTreeClassifier

Il s'agit ici de faire varier deux hyperparamètres, `splitter` et `max_features`.

- l'hyperparamètre `splitter` spécifie la stratégie utilisée pour choisir la méthode de fractionnement à chaque nœud. En plus d'agir sur la performance, celui-ci va permettre de fournir des résultats inédits (car l'aléatoire entre en compte). Il prendra ainsi deux valeurs possibles qui sont les suivantes : `'best'` et `'random'`
- l'hyperparamètre `max_features` spécifie le nombre maximal de critères qui vont être utilisés lors de la création de l'arbre. Le maximum (5) est représenté par le nombre de critères totaux dans le dataset. Celui-ci prendra les valeurs suivantes : $1, 2, 3, 4, 5$

RandomForestClassifier

Ce modèle, quant à lui, va se voir faire varier trois hyperparamètres, `n_estimators`, `max_features` et `bootstrap`.

- l'hyperparamètre `n_estimators` spécifie le nombre d'arbre d'arbre dans la fôret, c'est à dire le nombre d'échantillons sur lesquels cet algorithme va travailler. Il prendra les valeurs suivantes : $100, 200, 300, 400$
- l'hyperparamètre `max_features` est le même que pour le modèle "DecisionTreeClassifier"
- l'hyperparamètre `bootstrap` spécifie si des échantillons seront utilisés lors de la construction des arbres. Sinon, l'ensemble des données est utilisé pour construire chaque arbre. Celui-ci prendra deux valeurs possibles : `True` et `False`

KNeighborsClassifier

Nous allons utiliser un hyperparamètre : `n_neighbors`. Il spécifie le nombre de voisins à utiliser par défaut pour les requêtes kneighbors. Celui-ci est très important, car il agit directement avec et avec l'accuracy du modèle. Il prendra les valeurs possibles suivantes : $2, 4, 6, 8, 10, 12, 14, 16, 18, 20$

SGDClassifier

En plus des deux hyperparamètres cités dans les cas globaux, l'hyperparamètre `alpha` sera utilisé. Il définit la constante qui multiplie le terme de régularisation qui va agir sur le pas d'apprentissage de l'algorithme et donc la façon dont il va converger vers le minimum. Celui-ci prendra les valeurs suivantes : $0.01, 0.001, 0.0001, 0.00001$

Voici ci-dessous, la définition de notre fonction permettant de tester tous les modèles cités plus haut :

In [80]:
```
from sklearn.metrics import classification_report
bests = {}
def models(models, X, y):
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = .20, random_state = 100)
    data = {
        "parameters": [],
        "predict": [],
        "confusion_matrix": [],
        "precision": [],
        "recall": [],
        "specificity": [],
        "fpr": [],
        "fnr": [],
        "accuracy": [],
        "f1-score": [],
        "npv": [],
        "fdr": [],
        "auc": [],
        "roc-parameters": []
    }
    for model in models:
        path = "./outputs/models/"+ model["name"]
        if not os.path.isdir(path):
            os.makedirs(path)

        print(model["name"] + " : ")
        print("Start training...")

        search = GridSearchCV(
            model["method"],
            model["parameters"],
            cv=10,
            scoring='accuracy'
        )


        search.fit(X_train, y_train)
        print("Done!")

        data["parameters"].append(search.best_params_)
        model_predict = search.best_estimator_.predict(X_test)

        confusion = homemade_confusion_matrix(y_test, model_predict)

        data["predict"].append(model_predict)
        data["confusion_matrix"].append(confusion)

        precision = homemade_precision_score(y_test, model_predict)
        recall = homemade_recall_score(y_test, model_predict)

        data["precision"].append(precision)
        data["recall"].append(recall)
        data["specificity"].append(homemade_specificity_score(y_test, model_predict))
        data["fpr"].append(homemade_fpr_calculator(y_test, model_predict))
        data["fnr"].append(homemade_fnr_calculator(y_test, model_predict))
        data["accuracy"].append(homemade_accuracy_score(y_test, model_predict))
        data["f1-score"].append(homemade_f1_score(precision, recall))
        data["npv"].append(homemade_npv_calculator(y_test, model_predict))
        data["fdr"].append(homemade_fdr_calculator(y_test, model_predict))

        false_pos, true_pos, thresholds = roc_curve(y_test, model_predict)

        data["auc"].append(roc_auc_score(y_test, model_predict))
        data["roc-parameters"].append({
            "false_pos": false_pos,
            "true_pos": true_pos,
            "thresholds": thresholds
        })

        bests.update({model["name"]: search.best_estimator_})

    return pd.DataFrame(data, index=pd.DataFrame(models)["name"].to_numpy())
```

Et son appel avec les modèles concrets et leurs hyperparamètres :

In [81]:
```
models_indicators = models(
    [
        { # 180
            'name': 'DecisionTreeClassifier',
            'method': DecisionTreeClassifier(random_state=100),
            "parameters": {
                "splitter": ["best", "random"],
                "max_features": [1, 2, 3, 4, 5]
            }
        },
        { # 200
            'name': 'KNeighborsClassifier',
            'method': KNeighborsClassifier(),
            "parameters": {
                "n_neighbors": [2, 4, 6, 8, 10, 12, 14, 16, 18, 20],
                "weights": ["uniform", "distance"],
            }
        },
        { # 200
            'name': 'Ridge',
            'method': RidgeClassifier(random_state=100),
            "parameters": {
                "max_iter": [500, 1000, 1500, 2000],
                "tol": [0.1, 0.01, 0.001, 0.0001, 0.00001],
            }
        },
        { # 720
            'name': 'RandomForestClassifier',
            'method': RandomForestClassifier(random_state=100),
            "parameters": {
                "n_estimators": [100, 200, 300, 400] ,
                "max_features": [1, 2, 3, 4, 5] ,
                "bootstrap": [True, False],
            }
        },
        { # 800
            'name': 'Perceptron',
            'method': Perceptron(random_state=100),
            "parameters": {
                "max_iter": [500, 1000, 1500, 2000],
                "n_iter_no_change": [5, 10, 15, 20],
                "tol": [0.1, 0.01, 0.001, 0.0001, 0.00001],
            }
        },
        { # 800
            'name': 'SGDClassifier',
            'method': SGDClassifier(random_state=100),
            "parameters": {
                "max_iter": [500, 1000, 1500, 2000],
                "n_iter_no_change": [5, 10, 15, 20],
                "tol": [0.1, 0.01, 0.001, 0.0001, 0.00001],
            }
        },
        { # 800
            'name': 'SVC',
            'method': SVC(random_state=100),
            "parameters": {
                "max_iter": [500, 1000, 1500, -1] ,
                "kernel": ["linear", "poly", "sigmoid", "rbf"],
                "tol": [0.1, 0.01, 0.001, 0.0001, 0.00001],
            }
        },
        { # 900
            'name': 'LogisticRegression',
            'method': LogisticRegression(random_state=100),
            "parameters": {
                "max_iter": [100, 200, 300, 400, 500, 600],
                "solver": ["sag", "liblinear", "saga"],
                "tol": [0.1, 0.01, 0.001, 0.0001, 0.00001],
            }
        },
    ],
    X.to_numpy(),
    y.to_numpy()
)
```

```
DecisionTreeClassifier :
Start training...
Done!
KNeighborsClassifier :
Start training...
Done!
Ridge :
Start training...
Done!
RandomForestClassifier :
Start training...
Done!
Perceptron :
Start training...
Done!
SGDClassifier :
Start training...
Done!
SVC :
Start training...
Done!
LogisticRegression :
Start training...
Done!
```

Le résultat est exporté dans un fichier spécifique :

In [82]:
```
models_indicators.to_csv("./outputs/models/indicators.csv")
```

Étape n°4 - Interprétation des résultats

Sélection du meilleur modèle

Classement à partir de l'accuracy

Après avoir recueilli les meilleurs hyperparamètres de chaque modèle grâce à la méthode `GridSearchCV`, un premier classement des meilleurs modèles peut déjà être établi.

In [99]:
```
import matplotlib
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns

def display_info(infos, titles, labels, ymax=1.2, ylabel=''):
    fig, axs = plt.subplots(nrows=1, ncols=len(titles), figsize=(24, 6))

    if (len(titles) > 1):
        for j in range(0, len(titles)):
            axs[j] = give_data_to_display_as_hist(infos[j], labels, titles[j].capitalize(), axs[j], fig, 'C'+st
    else:
        axs = give_data_to_display_as_hist(infos, labels, titles[0].capitalize(), axs, fig, 'C1', ymax, ylabel)

    save_fig("./outputs/"+ ylabel + "_result")
    plt.show()

def give_data_to_display_as_hist(array, labels, title, ax, fig, color="C1", ymax=1.2, what=''):
    ind = list(np.arange(len(array)))
    bars = ax.bar(ind, array, 0.5, color=color)
    ax.set_title(title, fontsize=16)
    ax.set_xlim(-0.5, len(ind) + 0.5)
    ax.set_ylim(0, ymax)
    ax.set_ylabel(what)
    ax.set_xlim(-0.5, 3.5)
    ax.set_xticks(ind)
    ax.set_xticklabels(labels, fontsize=16)
    for rect in ax.patches:
        height = rect.get_height()
        if (np.issubdtype(height, np.integer) == False):
            height = np.around(height, 3)
        ax.annotate(height, xy=(rect.get_x()+rect.get_width()/2, height), xytext=(0, 5), textcoords='offset poi
    return ax;

def plot_roc_curve(false_pos, true_pos, ax, title=''):
    ax.plot(false_pos, true_pos, linewidth=2)
    ax.plot([0, 1], [0, 1], 'k--')
    ax.axis([0, 1, 0, 1])
    ax.set_title(title, fontsize=16)
    ax.set_xlabel('False Positive Rate', fontsize=16)
    ax.set_ylabel('True Positive Rate', fontsize=16)
    return ax
```

In [100…
```
datas = models_indicators
datas_accuracy_sorted = datas.sort_values(by='accuracy', ascending=False)
```

In [85]:
```
datas_accuracy_sorted[['accuracy']]
```

Out[85]:

	accuracy
RandomForestClassifier	0.938776
DecisionTreeClassifier	0.921769
KNeighborsClassifier	0.883220
LogisticRegression	0.862812
Ridge	0.848073
SVC	0.848073
Perceptron	0.757370
SGDClassifier	0.744898

D'après le classement, les modèles DecisionTreeClassifier, KNeighborsClassifier et RandomForestClassifier obtiennent un très bon score d'accuracy. Il est donc nécessaire de regarder en détail les différents scores.

Classement à partir de la precision, recall et F1-Score

In [86]:
```
datas_precision_sorted = datas.sort_values(by='precision', ascending=False)
datas_precision_sorted[['precision']]
```

Out[86]:

	precision
RandomForestClassifier	0.850877
LogisticRegression	0.809524
DecisionTreeClassifier	0.730496
KNeighborsClassifier	0.701299
Perceptron	0.305825
SGDClassifier	0.286385
Ridge	NaN
SVC	NaN

In [87]:
```
datas_recall_sorted = datas.sort_values(by='recall', ascending=False)
datas_recall_sorted[['recall']]
```

Out[87]:

	recall
DecisionTreeClassifier	0.768657
RandomForestClassifier	0.723881
Perceptron	0.470149
SGDClassifier	0.455224
KNeighborsClassifier	0.402985
LogisticRegression	0.126866
Ridge	0.000000
SVC	0.000000

In [88]:
```
datas_f1_sorted = datas.sort_values(by='f1-score', ascending=False)
datas_f1_sorted[['f1-score']]
```

Out[88]:

	f1-score
RandomForestClassifier	0.782258
DecisionTreeClassifier	0.749091
KNeighborsClassifier	0.511848
Perceptron	0.370588
SGDClassifier	0.351585
LogisticRegression	0.219355
Ridge	NaN
SVC	NaN

Selon les classements, les modèles Ridge et SVC fournissent un score incohérent (NaN ou 0), ils ne seronts donc pas sélectionnés dans les prochaines étapes. L'indicateur **recall** représentant le pourcentage d'employés quittant l'entreprise et étant bien détectés comme partant de l'entreprise est donc celui qui nous interesse le plus. Cependant, il faut que le modèle reste aussi **juste** (accuracy) dans notre cas. Les modèles sélectionnés sont donc les suivants : RandomForestClassifier, DecisionTreeClassifier, Perceptron et KNeighborsClassifier

In [101…
```
datas = datas_f1_sorted.head(4)
titles = ['accuracy', 'precision', 'recall', 'f1-score']
display_info(list(datas[titles].values), list(datas.index), titles, 1.2, 'Scores')
```

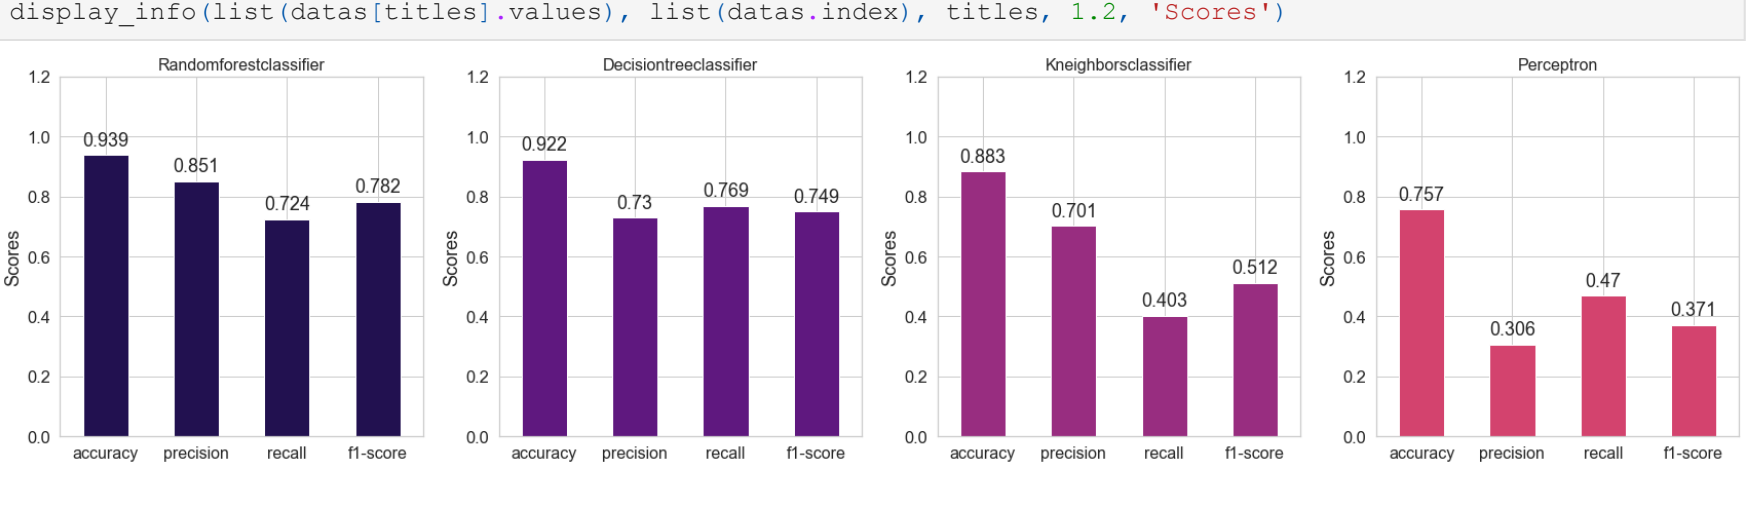

Courbe ROC et AUC

In [102…
```
all_roc_params = list(datas['roc-parameters'].values)
fig, axs = plt.subplots(nrows=1, ncols=len(all_roc_params), figsize=(20, 6))
for i in range(0, len(all_roc_params)):
    axs[i] = plot_roc_curve(all_roc_params[i]['false_pos'], all_roc_params[i]['true_pos'], axs[i], list(datas.i

print("Courbes ROC")
save_fig("./outputs/all_roc_result")
plt.show()
```

```
Courbes ROC
```

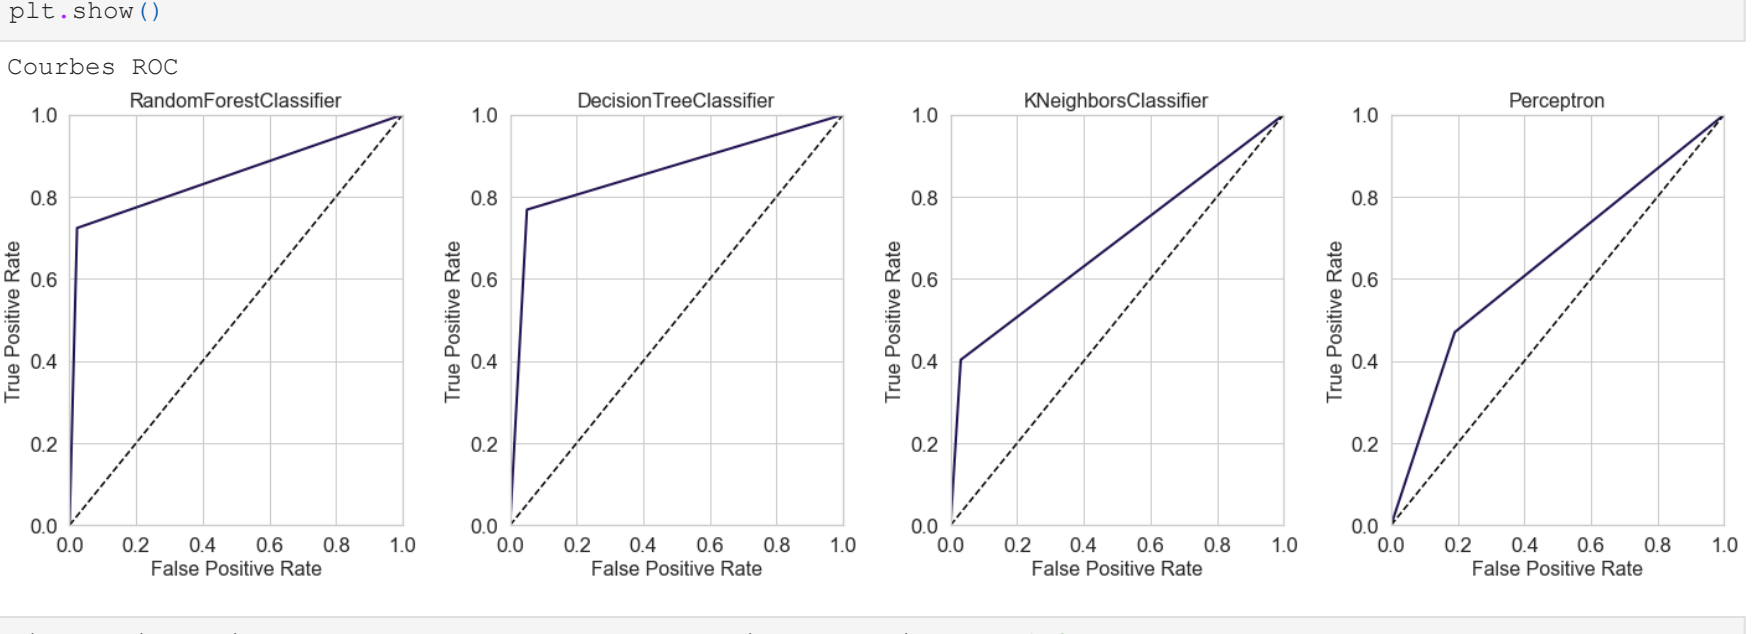

In [103…
```
display_info(list(datas.auc.values), ["AUC"], list(datas.index), 1.2, 'AUC')
```

D'après les courbes ROC, les DecisionTreeClassifier, RandomForestClassifier obtiennent un score AUC supérieur à 80%. Il va donc falloir choisir entre ces 2 modèles.

Sélection parmi les modèles restants

Il va falloir départager les modèles restant en prenant une autre donnée en compte que les indicateurs de qualité. Cela peut notamment se faire par l'observation de la différence de performance en temps d'exécution de ceux-ci.

In [92]:
```
# Importation des libraries
import time

from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=.20)
```

Calcul de la performance du modèle "DecisionTreeClassifier"

In [93]:
```
start = time.time_ns()
dtc = bests["DecisionTreeClassifier"]
dtc.fit(X_train, y_train)
dtc.predict(X_test)
end = time.time_ns()
dtc_time = (end - start) / 10**6
# Temps en ms
dtc_time
```

Out[93]:
```
5.0313
```

Calcul de la performance du modèle "RandomForestClassifier"

In [94]:
```
start = time.time_ns()
rfc = bests["RandomForestClassifier"]
rfc.fit(X_train, y_train)
rfc.predict(X_test)
end = time.time_ns()
rfc_time = (end - start) / 10**6
# Temps en ms
rfc_time
```

Out[94]:
```
458.7717
```

In [104…
```
display_info([dtc_time, rfc_time], ["Temps d'éxécution en ms"], ["DecisionTreeClassifier", "KNeighborsClassifie
```

Conclusion

Le modèle "DecisionTreeClassifier" est plus rapide que le modèle "RandomForestClassifier"

In [96]:
```
dtc_time < rfc_time
```

Out[96]:
```
True
```

Après analyse, les conclusions qui ont été apportées sur le choix du modèle reprennent les principaux axes de performances.

- La justesse
- La sensibilité
- La précision
- La rapidité

Le modèle choisi est donc le "DecisionTreeClassifier" car ses métriques présentent un score élevé comme le prouve sa justesse (accuracy) et sa sensibilité (recall). Étant donné que le modèle "RandomForestClassifier" possède des scores tous aussi élevés, la décision finale s'est axée sur la performance en termes de rapidité : cela représente le temps d'exécution de "DecisionTreeClassifier". Son temps d'exécution est beaucoup plus rapide par rapport au modèle "RandomForestClassifier".

Cela prouve une fois de plus que le modèle le plus adapté pour les besoins de l'entreprise HumanForYou est le "DecisionTreeClassifier".

Sélection du critère agissant le plus sur la décision des employés

In [97]:
```
import pandas as pd

data = {
    'Feature': list(X.columns),
    'Importance': list(bests["DecisionTreeClassifier"].feature_importances_)
}

selector = pd.DataFrame(data)
selector = selector.sort_values(by='Importance', ascending=False)
selector
```

Out[97]:

	Feature	Importance
4	AttendanceScore	0.278424
0	TotalWorkingYears	0.258455
1	YearsAtCompany	0.236693
2	YearsWithCurrManager	0.158289
3	EnvironmentSatisfaction	0.068139

In [105…
```
fig, ax = plt.subplots(figsize=(20, 5))
sns.set(style='whitegrid', palette='magma', font_scale=1.5)
sns.barplot(y='Feature', x='Importance', data=selector, ax=ax)
ax.bar_label(ax.containers[-1], fmt=' %.4f', label_type='edge', fontsize=16)

save_fig('./outputs/featureRank')
```

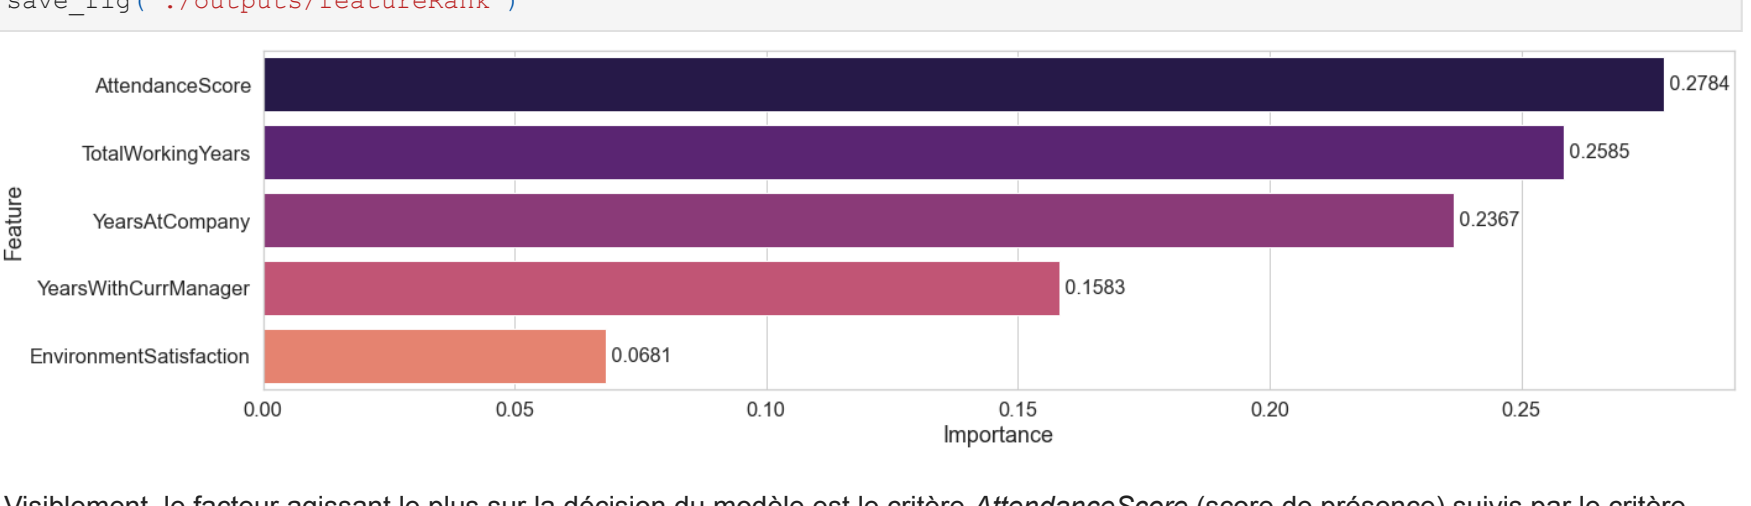

Visiblement, le facteur agissant le plus sur la décision du modèle est le critère *AttendanceScore* (score de présence) suivis par le critère *TotalWorkingYears* (nombre d'années d'expérience en entreprise du salarié pour le même type de poste) et enfin *YearsAtCompany* (nombre d'années d'expérience au sein de l'entreprise).

Interprétation des résultats

Concernant l'entrainement des modèles, nous avons donc trouvé que l'algorithme "*DecisionTreeClassifier*" était le plus adapté et donnait les meilleurs résultats pour nos données. Cet algorithme pourra donc être utilisé dans les prochaines années afin d'évaluer les probabilités de départ des employés ou encore de comparer si la mise en place de solutions (voir la partie "Pistes de solutions" ci-dessous) a vraiment eu un impact sur les salariés concernés.

L'analyse des colonnes influentes maintenant nous permet d'affirmer que ce turn-over dépend surtout de l'assiduité de l'employé à travailler en suivant le nombre d'heures prévu sur son contrat ainsi que ses années d'expériences (à la fois pour le même type de poste et pour l'ancienneté dans l'entreprise). Ceci pourrait s'expliquer notamment par des baisses de motivation ou tout simplement de sérieux des salariés après des années à travailler dans l'entreprise pour le même poste.

Enfin, même si notre modèle est désormais défini, son utilisation ne s'arrête pas ici. En effet, il est important de savoir que nos résultats peuvent encore être améliorés et ceci de plusieurs manières :

- Amélioration du processus de préparation des données si cela est possible
- Collecte ou généreration de nouvelles données
- Sélection d'autres colonnes pertinentes si cela est possible (et en accord avec la démarche éthique)
- Utilisation de métriques d'évaluation différentes et pertinentes

Pistes de solutions

En plus de faire les sondages de satisfaction annuels, l'idéal serait de demander plus de détails sur le bien-être de l'employé dans l'entreprise, que ce soit à propos de son environnement, des relations humaines ou encore du poste occupé en lui-même. Prendre en compte ces détails sera utile pour améliorer la qualité de vie des employés et ainsi leur donner envie de rester. Il serait aussi nécessaire d'augmenter la fréquence de ces sondages en les rendant semestriels. Ensuite, diversifier les missions sur un poste, donner plus de responsabilités ou réorienter la personne si celle-ci n'est pas épanouie sur ce poste permettra de rompre les actions répétitives et de donner de l'importance à la personne. Si le travail est bien fait, il ne faut pas hésiter à récompenser le travail. Enfin, si tous ces conseils sont appliqués, l'assiduité aura de grandes chances d'augmenter et moins d'employés voudront alors quitter les équipes.

Conclusion

Pour conclure, ce modèle retourne bien un résultat cohérent en représentant les critères dans l'ordre de l'histogramme ci-dessus. Les pistes de solutions proposées doivent être sérieusement prises en compte afin d'exploiter au maximum les résultats trouvés lors de cette étude et d'améliorer l'environnement de travail global. La personne en charge de ce modèle doit également prendre en compte le fait que celui-ci est potentiellement améliorable si certaines données viennent à être ajoutées dans le futur, le but étant de conserver les démarches de réflexion et d'éthiques mises en place autour. Cependant, il ne faut pas oublier que cet outil a été conçu dans l'optique d'informer l'utilisateur et donc notamment l'entreprise. En aucun cas cette intelligence artificielle ne doit avoir un pouvoir de décision sur les mesures adoptées suite à la prise de connaissance des données qu'elle fournit à l'entreprise. L'humain reste le seul et unique décisionnaire final.